

Guía práctica

Primer clasificador en Excel con regresión logística y Solver

Propósito

Construir un clasificador reproducible, evaluar sus errores en una muestra de prueba y traducir las métricas a una decisión de negocio.

Qué necesita

- Microsoft Excel con Power Query y el complemento Solver.
- Los archivos clientes.csv y campanas.csv.
- Una copia de trabajo: no modifique los archivos originales.
- Excel configurado con separador decimal coma y separador de argumentos punto y coma. Si su Excel está en inglés, traduzca los nombres de las funciones.

Dónde están los datos

Carpeta: data/public/clasificacion/
- clientes.csv
- campanas.csv
- base_modelable_referencia.csv
- diccionario_clasificacion.csv

Archivo	Contenido	Filas
clientes.csv	Perfil demográfico y financiero del cliente	7.980
campanas.csv	Contexto de campaña y respuesta acepta_deposito	7.960
Cruce interno esperado	Registros con id_cliente en ambas tablas	7.940

Auditoría

El ejercicio contiene deliberadamente 40 clientes sin campaña y 20 campañas sin perfil. La diferencia de filas es parte del análisis, no un error accidental.

Ruta rápida

Si el objetivo de la clase es concentrarse en el clasificador, importe directamente base_modelable_referencia.csv. Si el objetivo incluye preparación, realice primero el cruce descrito en la página siguiente.

1. Preparar la base con Power Query

Paso 1. Importar clientes

Abra un libro nuevo. Vaya a Datos - Obtener datos - Desde texto/CSV, seleccione clientes.csv y elija Transformar datos.

Paso 2. Importar campañas

Repita el proceso con campanas.csv. Confirme que ambas consultas reconocen id_cliente como texto.

Paso 3. Combinar

Seleccione la consulta campanas y use Inicio - Combinar consultas. Relacione ambas tablas mediante id_cliente.

Compare antes de elegir

Tipo de cruce	Qué conserva	Pregunta de negocio
Interno	Solo las 7.940 llaves presentes en ambas tablas	¿Aceptamos excluir registros sin pareja?
Izquierdo desde campañas	Las 7.960 campañas	¿Cómo trataremos los 20 perfiles ausentes?

Paso 4. Expandir y cargar

Expanda las columnas de clientes, evite duplicar id_cliente y cargue el resultado como tabla de Excel. En Diseño de tabla, asigne el nombre Base.

Control antes de modelar

- Una fila representa un contacto asociado a un cliente.
- La respuesta es acepta_deposito.
- La predicción se realiza antes de contactar al cliente.
- El identificador id_cliente no se usa como predictor.
- Un blanco no significa lo mismo que la categoría unknown o nonexistent.

No usar	No incluya la duración de la llamada para decidir a quién contactar: solo se conoce después de la llamada y produciría fuga de datos.
---------	---

2. Diseñar el primer clasificador

Para que el mecanismo sea visible en Excel, el primer modelo utiliza cinco predictores. No busca maximizar desempeño: busca mostrar cómo una probabilidad se convierte en una decisión.

Predictor	Tipo	Preparación
edad	Numérico	Usar el valor observado
contactos_campana	Numérico	Usar el valor observado
contactos_previos	Numérico	Usar el valor observado
tipo_contacto	Categorico	Crear indicador de celular
resultado_previo	Categorico	Crear indicador de success

Crear la respuesta numérica

```
y = --([@acepta_deposito]="Sí")
```

Crear variables indicadoras

```
x_celular = --([@tipo_contacto]="cellular")  
x_exito_previo = --([@resultado_previo]="success")
```

Separar entrenamiento y prueba

Agregue una columna particion. La fórmula genera una división estable cercana a 75 % / 25 %:

```
=SI(RESIDUO(VALER(DERECHA([@id_cliente];6));4)=0;  
"Prueba";"Entrenamiento")
```

Regla

Solver solo debe aprender con Entrenamiento. La matriz de confusión y las métricas deben calcularse únicamente con Prueba.

Crear los parámetros

En una hoja denominada Parametros, escriba estos valores iniciales:

Celda	Parámetro	Valor inicial
B2	Intercepto	0
B3	Edad	0
B4	Contactos de campaña	0
B5	Contactos previos	0
B6	Contacto celular	0
B7	Éxito previo	0

3. Construir la probabilidad logística

En la tabla Base, cree la columna z. Esta es la combinación lineal de variables y coeficientes:

```
=Parametros!$B$2  
+Parametros!$B$3*[@edad]  
+Parametros!$B$4*[@contactos_campana]  
+Parametros!$B$5*[@contactos_previos]  
+Parametros!$B$6*[@x_celular]  
+Parametros!$B$7*[@x_exito_previo]
```

Cree después la columna p:

```
=MAX(1E-8;MIN(1-1E-8;1/(1+EXP(-[@z]))))
```

La función logística transforma cualquier valor de z en una probabilidad entre 0 y 1. Los límites 1E-8 y 1-1E-8 evitan calcular LN(0).

Construir la pérdida de entrenamiento

Agregue la columna loglik_entrenamiento:

```
=SI([@particion]="Entrenamiento";  
[@y]*LN([@p])+(1-[@y])*LN(1-[@p]);  
0)
```

En Parametros!B10, escriba la pérdida total que Solver debe minimizar:

```
=-SUMA(Base[loglik_entrenamiento])
```

Importante

La herramienta Análisis de datos - Regresión ajusta una regresión lineal. Para este ejercicio no reemplaza la regresión logística.

Activar Solver

Si Solver no aparece, use Archivo - Opciones - Complementos - Administrar complementos de Excel - Ir y active Solver.

4. Ajustar el modelo con Solver

Abra Datos - Solver y configure:

Campo	Configuración
Definir objetivo	Parametros!B10
Optimizar	Mínimo
Cambiando las celdas	Parametros!B2:B7
Método	GRG No lineal

Crítico

En Opciones, desmarque Convertir variables sin restricciones en no negativas. Los coeficientes logísticos pueden ser positivos o negativos.

Presione Resolver y conserve la solución. Si Solver no converge:

- revise que edad y los conteos sean numéricos;
- confirme que las probabilidades no contengan errores;
- verifique que la pérdida solo incluya Entrenamiento;
- reinicie B2:B7 en cero y vuelva a ejecutar;
- como medida de estabilidad, puede restringir los coeficientes entre -20 y 20.

Convertir probabilidades en clases

Agregue la columna predice con un punto de corte inicial de 0,5:

=SI([@p]>=0,5;1;0)	
Probabilidad	Decisión inicial
p >= 0,5	Predice aceptación: 1
p < 0,5	Predice no aceptación: 0

El punto de corte no pertenece al algoritmo como una verdad universal. Es una regla de decisión que puede modificarse según el costo de falsos positivos y falsos negativos.

5. Evaluar en la muestra de prueba

Construya la matriz únicamente con filas cuya partición sea Prueba.

Verdaderos positivos - TP

```
=CONTAR.SI.CONJUNTO(Base[particion];"Prueba";Base[y];1;Base[predice];1)
```

Falsos positivos - FP

```
=CONTAR.SI.CONJUNTO(Base[particion];"Prueba";Base[y];0;Base[predice];1)
```

Falsos negativos - FN

```
=CONTAR.SI.CONJUNTO(Base[particion];"Prueba";Base[y];1;Base[predice];0)
```

Verdaderos negativos - TN

```
=CONTAR.SI.CONJUNTO(Base[particion];"Prueba";Base[y];0;Base[predice];0)
```

Calcular las métricas

Métrica	Fórmula	Pregunta que responde
Exactitud	$(TP+TN)/(TP+FP+FN+TN)$	¿Qué proporción total acertó?
Precisión	$TP/(TP+FP)$	De los contactados, ¿cuántos aceptarían?
Recall	$TP/(TP+FN)$	De quienes aceptarían, ¿cuántos detectamos?
Especificidad	$TN/(TN+FP)$	¿Cuántos no aceptantes evitamos contactar?
F1	$2*Precisión*Recall/(Precisión+Recall)$	¿Qué equilibrio existe entre precisión y recall?

6. Interpretar antes de recomendar

Línea base

Como cerca de 89 % de los casos corresponde a No, un clasificador que siempre predice No puede obtener una exactitud cercana a 89 % y un recall de aceptantes igual a 0 %.

Preguntas para el grupo

- ¿El modelo predijo alguna aceptación?
- ¿Cuántos aceptantes reales dejó escapar?
- ¿Cuántas llamadas improductivas generó?
- ¿Qué cambia al bajar el punto de corte a 0,30 o 0,20?
- ¿Cuál error es más costoso para el escenario analizado?

Dos escenarios

Escenario	Error más costoso	Prioridad
Crecimiento	No contactar a alguien que habría aceptado - FN	Recall
Capacidad limitada	Contactar a alguien que no aceptará - FP	Precisión

Formato de conclusión

"Para [escenario], elegiría el modelo con [métrica] de [valor], porque el error más costoso es [FP o FN]. Con el corte [valor], el modelo produce [conteo] errores de ese tipo. No podemos concluir causalidad."

Lista de comprobación final

- El cruce y las exclusiones quedaron documentados.
- La llave no fue utilizada como predictor.
- Entrenamiento y prueba están separados.
- Solver utilizó únicamente entrenamiento.
- La matriz utiliza únicamente prueba.
- La recomendación relaciona una métrica con el costo de un error.
- La conclusión declara límites y no confunde predicción con causalidad.

Idea central

Solver estima los coeficientes; el punto de corte convierte probabilidades en decisiones; el costo del error define si la decisión es adecuada.

Material público de la sesión 5